

动态设置自适应参数下界

张柯远, 11812714

摘要——自适应遗传算法 EP 中 η 的下界和优化的结果有着密切的联系。然而 η 的下界和优化的问题有着高度的相关性[1], 因此自适应地设置 η 的下界可以使 EP 算法具有更强的适应性。本文讨论了[2]中提出的固定间隔更新 η 下界的算法 DLB2 可能会出现 η 无法收敛的问题, 并根据该算法设计了一个能够动态调节更新间隔的算法 DLB2'。论文中还将展示 FEP[1]和 DLB2' 算法在多个目标函数上的比较, 并且具体分析 DLB2' 在单峰函数, 上位性函数, 多峰函数的不同表现, 以及 η 的变化情况。实验结果表明 DLB2' 在单峰函数上能够有效地设置 η 的下界并且取得比 FLB[2]更好的结果。但是在上位性函数, 多峰函数中仍存在一些问题。

关键词—遗传算法, 自适应, 动态更改更新间隔

I. 引言

传统的自适应遗传算法 evolutionary programming (EP) 利用参数 η 来控制种群中每个个体每个分量的突变步长[1]。但是随着迭代次数的增加, η 突变成一个非常小的数的概率也会增加, 这被称为步长控制丢失[2]。一些研究证明设置一个合适的 η 下界可以有效地改善 EP 的性能[3]。因此, 本文基于一种固定迭代间隔更新 η 下界的算法 IFEP_DL2[2], 提出能够动态地改变更新下界的时刻的算法 IFEP_DL3。

论文之后的内容如下: 第二部分会讨论固定迭代间隔可能会带来的问题。第三部分会提出修改算法的思路以及算法的伪代码。第四部分会将第三部分提出的算法和固定 η 下界的 FEP[1]算法比较并展示实验数据。基于第四部分的实验, 第五部分会分析 IFEP_DL3 对于 η 下界在不同目标函数上的影响。最后第六部分会总结上文中的重点以及可改进的方向。

II. 固定间隔的更新下界

在论文[2]中, η 的第 κ 下界 $\eta_{\kappa+1}$ 是每隔5代更新成当前被接受的子代的 η 每个分量的中位数, 原论文中的公式如下:

$$\bar{\delta}(j) = \frac{1}{m} \sum_{i=1}^m \delta_v(j), \quad j = 1, \dots, n$$
$$\eta_{\kappa+1} = \text{median}\{\bar{\delta}(j), \quad j = 1, 2, \dots, n\} \quad (1)$$

其中 j 代表第 j 个分量, m 代表被接受的子代的个数, n 表示的是每个个体的维度。显然, 如果更新下界的间隔设置的过大, 那么会出现 loss of step size control 的情况。不过, 当间隔设置的太小, 则 η 有可能向另一个极端发展, 即变得过大。可以证明, 如果不考虑选择(selection)对 η 的影响, 随着迭代次数的增加, η 中出现过大的值的概率也会增大。证明的思路和[2]中有关步长控制丢失概率的证明非常相似, 只需将小于号换成大于号, 便可对称地得到:

$$\forall A, A > 0, \frac{\partial}{\partial \kappa} P(\eta^{\kappa}(j) > A) > 0, \text{当 } A > \eta^0(j) \quad (2)$$

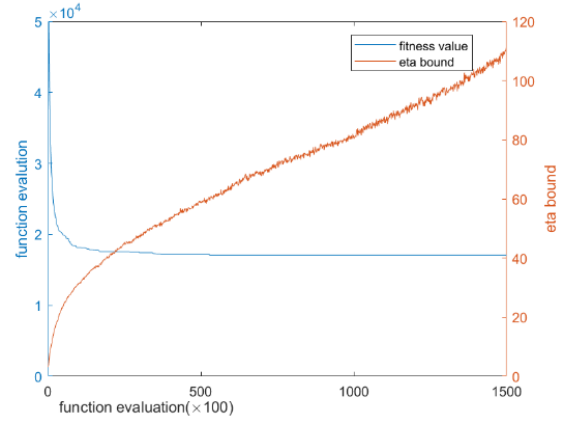


图 1 间隔为5时每代最优目标函数值以及 η 下界的变化。结果为30次的平均值。

其中 j 代表第 j 个分量, $\eta^0(j)$ 是 η 第 j 个分量的初始值。从这个结论可以看出, 随着迭代次数的增加, 会出现一些非常大的 η 值。实际上, 根据 η 突变的公式[3]:

$$\eta^{\kappa+1}(j) = \eta^{\kappa}(j) \exp(\tau N(0, 1))$$

η 的取值符合对数正太分布(logarithmic normal distribution)。对数正态分布的期望等于 $e^{\mu+\sigma^2/2}$, 当迭代次数 κ 增加时, 参数 σ 也会增加, 整体的期望会上升。因此, 如果过于频繁地将下界设置为 η 各部分分量均值的中位数, 会导致整体 η 的值不断上升。而 η 的值过大会导致算法找到更优解的概率降低[1], 从而导致算法无法继续。

我在30维的球函数 $f(x) = \sum_{i=1}^{30} x_i^2$ 用(10+10) EP 算法进行了实验。最大评估次数为十五万次。初始的 η 都设为3。图一展示了当固定更新间隔为5时 η 下界随迭代次数的变化情况。图中的结果是30次运行的平均值。可以看到 η 的下界随着迭代次数的增加不断地上升, 同时最优目标函数值也很快不再变化。

III. 动态更新间隔

根据部分 II 中, 过大的 η 会使得找到更优解的概率降低, 因此只要足够长的迭代次数, survival selection 便能够将带有过大 η 的个体剔除。因此, 整个动态更新间隔的算法 DLB2' 只需根据 η 的变化, 调整更新下界的间隔, 从而控制 η 的下界。

下界的数值参考了论文[2]中 DLB2 的公式, 并在其基础上做了滑动平均的处理, 使得下界的变化更加平滑, 公式如下, 其中 α 的值为0.875:

$$\eta_{\kappa+1} = \alpha * \eta_{\kappa} + (1 - \alpha) * \text{median}\{\bar{\delta}(j), \quad j = 1, 2, \dots, n\} \quad (3)$$

Algorithm 1 IEPF_Mutation

Input: parents
Output: offspring
1: $\tau = 1/\sqrt{2\sqrt{\mu}}$
2: $\tau' = 1/\sqrt{2\mu}$
3: **for** all individual in parents **do**
4: **for** $j = 1$ to n **do**
5: $\eta(i, j) = \eta(i, j) * \exp(\tau * rand + \tau' * rand_j)$
6: $child_1 = parents(i, j) * cauchy(0, 1)$
7: $child_2 = parents(i, j) * gauss(0, 1)$
8: **if** $eval(child_1) \leq eval(child_2)$ **then**
9: $offspring(i, j) = child_1$
10: **else**
11: $offspring(i, j) = child_2$
12: **end if**
13: **end for**
14: **end for**

Algorithm 2 IEPF_Selection

Input: parents, offspring
Output: acc_offspring
1: tournament_size = 10
2: total = [parents, offspring]
3: tournament_score = []
4: **for** i in $2 * \mu$ **do**
 opponent = select tournament_size from parents
 and offspringtournament[i] = # of opponent has
 smaller fitness value than total(i)
5: **end for**
6: index = argsort(tournament_score)(1: μ)
7: acc_offspring = total[index]

当到达下一次更新下界时，首先判断当前 $median\{\delta(j)\}$ 是否小于上一次的下界。如果小于，则将更新的间隔设置成原来的一半并且把所有小于下界 η_{-} 的 η 改为 η_{-} 。否则，将更新的间隔增大十倍，不更新 η_{-} 。每次到达更新间隔时都会根据(3)更新 η_{-} 的值。

算法的其他部分同 $(\mu + \lambda)$ IFEP[1]。每一次迭代，每一个个体都会用柯西随机变量和高斯随机变量突变生成两个子代，然后选择适应度函数更高的子代作为其真正的子代。在选择部分，采用锦标赛选择的算子，将 tournament size 设为 10，从父代和其真正的子代中选出下一次迭代的子代。

Algorithm 1 和 2 展示了突变和选择部分的伪代码。Algorithm 3 主要展示了如何更新 η 和间隔的部分，其余部分同 IFEP[1]。

IV. 实验结果

A. 实验参数设置

为了验证 DLB2' 的性能，本次实验还实现了 FEP 算法 [1] 与其进行对比。实验测试的目标函数为 $f1-f12, f13$ [1]。对于 FEP，种群的数量设为 100， η 的固定下界是 0.0001，初始值为 3。DLB2' 的种群数量为 3， η 的初始值也为 3。种群的初始化是在定义域范围内的随

Algorithm 3 IEPF_DLB2'

Input: func
Output: bestx, besty
1: Initialization
2: count = 1
3: **while** stop criteria is not true **do**
4: $offspring = mutate(\mu)$
5: $\mu = tournament_selection(\mu, offspring)$
6: **if** count is equal to α **then**
7: $\delta = \text{median of mean of } \mu\text{'s component}$
8: **if** $\delta \leq \mu b$ **then**
9: $\alpha = \alpha + 10$
10: **else**
11: **for** all μ_i in μ **do**
12: $\mu_i = \max\{\mu b, \mu_i\}$
13: $\alpha = \lfloor \alpha/2 \rfloor$
14: **end for**
15: **end if**
16: $\mu b = 0.875 * \mu b + 0.125 * \delta$
17: count = 1
18: **end if**
19: count += 1
20: **end while**

机分布。

B. 实验结果

表一展示了实验的结果。其中 Mean Best 表示函数最后一次迭代产生的最优解的目标函数值的平均值，Std Dev 表示从表中可以看出。DLB2' 算法在 $f1-f4, f10, f11$ 中都取得了更好的结果。但是在 $f5, f7, f8, f9, f13$ 中的效果都要差于固定间隔的 FEP 算法。再下一部分会针对单峰函数 $f1, f5$ (rosenbrock 函数) 以及多峰函数 $f8, f9, f13$ 具体分析 DLB2' 的运行情况。

V. 实验结果分析

A. 单峰函数

在很多单峰函数上，DLB2' 都比固定间隔的 IFEP_FLB 取得了更好的结果。如图 2 中所示，DLB2' 目标函数的收敛速度明显快于 FLB。

为了验证在 $f1$ 上 DLB2' 真的能够合理地设置 η ，我又在 $f1$ 进行了一次相同的实验。这次实验统计了每一次迭代 selection 后的子代中最小的 η 值以及 η 的下界变化。从图 3 可以看出， η 的最小值随着 η 下界不断地下降，最后会到 $1e^{-8}$ 。这是明显低于固定下界的 0.0001 的。第二点， η 的最小值会不停地抖动，这也验证了随着迭代次数的增加，的确会突变出现过小的 η 值。这说明 DLB2' 能够根据 η 的变化，改变 η 的下界，使得寻找最优解的速度得到了一定的加快。

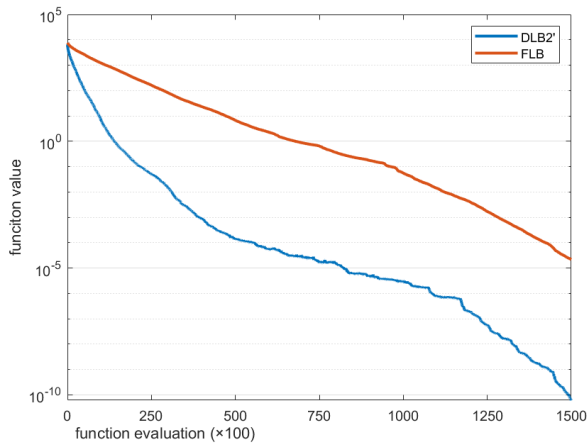


图 2 对比 IFEP_DLBB2' 与 FEP_FLB 在 f_1 上目标函数收敛的情况。横坐标为函数评估次数，纵坐标为目标函数值。结果是 30 次的平均值。




图 3 η 下界和目标函数值得的变化曲线。蓝色是目标函数的收敛曲线，橙色是每代 η 值的最小值，黑色虚线是算法中设置的 η 下界。实验结果是 30 次的平均值。

表格 1 在 $f_1 - f_{11}, f_{13}$ 上比较 IFEP_DLBB2' 和 FEP_FLB。其中 Mean Best 表示

Function	# of Evaluation ($\times 100$)	IFEP_DLBB2'		FEP_FLB		DLB2' - FLB
		Mean Best	Std Dev	Mean Best	Std Dev	Signrank
f_1	1500	2.89E-10	1.51E-9	1.16E-4	3.29E-4	-4.78
f_2	2000	1.75E-4	4.16E-4	1.81E-2	6.77E-4	-4.78
f_3	5000	1.28E-16	2.69E-16	0.88	1	-4.78
f_4	5000	1.48E-15	3.73E-15	0.02	0.04	-4.78
f_5	20000	12.69	7.23	5.31	4.43	3.34
f_6	1500	0	0	0	0	0
f_7	3000	3.54E-2	1.37E-2	1.43E-2	7.4E-3	4.78
f_8	9000	-10899	358.25	-11409	365.96	3.69
f_9	5000	31.24	9.23	0.69	0.90	4.78
f_{10}	1500	2.40E-5	5.86E-5	5.60E-3	6.1E-3	-4.78
f_{11}	2000	1.86E-2	1.56E-2	9.75E-2	0.21	-2.25
f_{13}	100	-5.17	3.92	-9.00	3.83	4.29

B. f_5 函数

f_5 在某些方向上的下降速度非常缓慢，因此将整体 η 所有分量的中位数作为每个分量的下界有可能会导导致一些分量上的 η 太早地收敛，从而导致优化的速度变慢。从图 4 中可以看出，DLB2' 目标函数值很快就停止了下降，而 FLB 却可以持续缓慢地下降。

为了验证 DLB2' 的 η 在某些分量上被其他分量影响，我选择两者第 30 个维度上的 η 值进行比较，因为第 30 维向函数全局最优解下降的梯度最小。从图 5 中的对比可以看出 DLB2' 的 η 要明显小于 FLB 的 η 值，最开始下降的速度也是 DLB2' 的更快。而 DLB2' η 值尽管会因为不断设置下界而上下波动，但是因为下界明显低于 FLB 固定的下界，因此在第 30 维方向上突变的步长也会小于 FLB。

C. 多峰函数

DLB2' 在多峰函数上的效果都不如 FLB。在分析了多个多峰函数上 DLB2' 的 η 的均值变化的情况后，我总结出了可能的原因：尽管动态的调整更新下界的迭代间隔可以减少 η 过小或者过大带来的影响，但是并不

能调整至当前状态合适的步长。换言之，有时候 η 收




图 4 在 f_5 上比较 FLB 和 DLB2' 的目标函数收敛曲线。蓝色表示 DLB2'，橙色表示 FLB。实验的结果是 30 次的平均值。




图 5 f_5 上 FLB 和 DLB2' 第 30 维 η 的均值的变化情况。蓝色代表 FLB，橙色代表 DLB2'。收敛的速度很快，因为 DLB2' 贪心地选取子代的 η 的均值作为下界，所以下界收敛的速度也会很快，最终导致突变步长过短无法继续优化；也有可能当 η 过大，收敛的速度较慢时， η 的均值下降缓慢。但是 DLB2' 持续地设置下界会渐慢 η 下降的速度，使得 η 不能或需要很长时间下降到合适的大小，因此优化也很难进行下去。

图 6 展示了收敛速度过快的情况。图中可以看到当 DLB2' 很快地收敛到一定程度时便停在了局部最优解无法继续优化。图 8 展示了 DLB2' η 下界和 FLB η 均值的对比。从图 8 可以看出，DLB2' 的 η 在迅速下降，并一直低于 FLB 的 η 值。这和图 6 的目标函数收敛曲线是一致的。

图 7 和图 9 展示了 f_9 上 DLB2' 和 FLB 的情况。除了 f_8 中出现的 η 收敛速度过快导致突变步长过小的情况，还在迭代的初期出现 η 收敛过慢，优化暂时停止的情况。从图 7 可以看出，在 100000 到 200000 次评估之间，当前最优的目标函数值都没有下降，明显小于慢于 FLB。而从图 9 中可以看到，在这个区间里 η 的均值也没有下降，而 FLB 有明显的下降。这和图 7 中的现象是符合的。而从 250000 次评估之后，DLB2' 的 η 收敛速度过快，导致步长提前过小。

总之，在多峰函数上，DLB2' 表现出 η 下界无法合理地控制步长。在 η 下降速度过快或者过慢导致无法继续优化时，都不能有效地减缓或者加速 η 收敛速度。

VI. 总结

论文中讨论分析了在 EP 算法中固定间隔更新 η 下界可能会导致的问题，并由此问题出发提出依据 η 均值变化趋势动态更改时间间隔的算法 DLB2'。实验的结果表明，DLB2' 可以有效地避免丢失步长控制以及步长不断增大的问题，并且在一些单峰函数上取得了比固定 η 下界更可观的结果。但是 DLB2' 依然存在很多问题。在 f_5 函数上表现出某些 η 的某些分量会受到其他分量的影响导致过小。另外，动态更新间隔不能反映出合适的突变步长。因此在多峰函数中， η 有时过早地收敛至很小的数，有时又在较大时卡住。这些都会导致找不到最优解或者目标函数收敛缓慢。




图 6 在 f_8 上比较 FLB 和 DLB2' 的目标函数收敛曲线。蓝色表示 DLB2'，橙色表示 FLB。实验的结果是 30 次的平均值。




图 7 在 f_9 上比较 FLB 和 DLB2' 的目标函数收敛曲线。蓝色表示 DLB2'，橙色表示 FLB。实验的结果是 30 次的平均值。




图 8 f_8 上比较 FLB 和 DLB2' 的 η 变化。黄色是 FLB，橙色是 DLB。

基于上述的种种问题，该实验未来可以从以下两个角度研究：一是如何定义 η 的下界。可以考虑将 η 整体的均值和 η 各个分量结合在一起，使得分量之间不会因为互相影响而导致在某一方向上过大或过下。二是除了 η 均值的变化外，寻找其他的先验信息来决定更新

下界的时间间隔。使得下界的更新能反映出当前种群合适的突变步长。

REFERENCES

- [1] X. Yao, Y. Liu and G.M. Lin, "Evolutionary programming made faster," in *IEEE Transactions on Evolutionary Computation*, vol. 3, no. 2, pp. 82-102, July 1999.
- [2] Liang, Ko Hsin, X. Yao and C. S. Newton, "Adapting Self-Adaptive Parameters in Evolutionary Algorithms," in *Applied Intelligence*, vol. 15 no. 3 pp.171-180, 2001.
- [3] T. Bäck and H.-P. Schwefel, "An overview of evolutionary algorithms for parameter optimization," *Evol. Comput.*, vol. 1, no. 1, pp. 1-23, 1993.




图9 f_9 上比较 FLB 和 DLB2' η 的均值变化。黄色是 FLB，橙色是 DLB。